

ВЕСНА НА ДВОРЕ: 300 000 ТОКЕНОВ ДЛЯ ВАШИХ ПРОЕКТОВ



512K+

Охват за 30 дней

BotHub

Bothub — экосистема AI инструментов

378,71 Рейтинг

1 332 Подписчики

[Подписаться](#)

dmitrifriend

10 часов назад

Лучшие LLM в 2026 году: Какую нейросеть выбрать сегодня?

[Простой](#) [20 мин](#) [8.2K](#)

Блог компании BotHub, Искусственный интеллект, Контент и копирайтинг*, Программирование*, Софт

[Обзор](#)

Ладно, признаюсь честно: когда я начинал писать этот материал, у меня было открыто девять вкладок с чат-ботами одновременно. Каждый обещал быть “лучшим”, каждый хотел мне помочь, и

все они давали немного разные ответы на один и тот же вопрос. Это, собственно, и есть 2026 год в мире ИИ – изобилие, от которого кружится голова.

⇒ “Что-то важное происходит, но я не понимаю, что именно” – примерно так чувствует себя среднестатистический пользователь, который открывает очередную новость про ИИ и видит там снова три буквы: LLM.

Рынок LLM (large language model, “большая языковая модель”, или попросту “чат-бот”) сейчас похож на тот момент, когда ты приходишь в большой супермаркет за йогуртом, а там 47 видов йогурта, и ты стоишь перед полкой уже шесть минут. Только ставки повыше: от выбора правильной модели зависит качество вашего кода, текстов, аналитики – и в конечном счёте рабочее время.

Эта статья – попытка навести порядок. Никаких абстрактных рейтингов “по ощущениям”: только конкретные факты, бенчмарки, реальные примеры использования и честное мнение о том, когда та или иная модель действительно полезна.

Разберём 12 актуальных решений – от агрегатора нейросетей до локальных открытых моделей: BotHub, Gemini 3 Flash, Gemini 3.1 Pro, Grok 4.20, ChatGPT 5.4, ChatGPT 5.4 Pro, Claude Opus 4.7, Claude Sonnet 4.6, DeepSeek v3.2, Perplexity Sonar, Gemma 4 26B A4B, GPT-OSS-120B.

~ О Г Л А В Л Е Н И Е ~

- BotHub – все модели в одном окне
- Gemini 3 Flash – быстрый и умный
- Gemini 3.1 Pro – флагман от Google
- Grok 4.20 – четыре агента вместо одного
- ChatGPT 5.4 – новый стандарт
- ChatGPT 5.4 Pro – для задач уровня PhD
- Claude Opus 4.7 – новейший флагман Anthropic
- Claude Sonnet 4.6 – золотая середина
- DeepSeek v3.2 – китайское открытое чудо
- Perplexity (Sonar) – поиск нового поколения
- Gemma 4 26B A4B – на вашем ноутбуке
- GPT-OSS-120B – OpenAI открывает карты

1) BotHub – все модели в одном окне

Начнём с главного секрета этой статьи. Доступ к большинству описанных здесь моделей из России превращается в отдельный квест: смена IP, иностранная карта, блокировки. **BotHub** убирает всё это разом.

BotHub – российский агрегатор нейросетей, и его главная суперсила – доступность. Он собрал под одной крышей практически всё, что сейчас есть на рынке. Уже сейчас в нём: Gemini 3 Flash, ChatGPT 5.4 Pro, Claude Opus 4.7, Claude Sonnet 4.6, ChatGPT 5.4, Gemini 3.1 Pro, Grok 4.20, DeepSeek v3.2, Perplexity Sonar – и ещё десятки других моделей. Фактически всё, о чём написано в этой статье, можно попробовать в одном интерфейсе без VPN и иностранных карт.

Помимо текстовых моделей, платформа предлагает генерацию изображений (Midjourney, Flux, DALL-E, Stable Diffusion), работу со звуком (транскрибация и синтез речи), генерацию видео через Runway и Veo. Есть также **Easy Writer** – инструмент для создания структурированного контента – и телеграм-бот-модератор на базе LLM.

Для разработчиков BotHub предоставляет полноценный API, совместимый с форматом OpenAI. Конечные точки идентичны, документация доступна на русском. Это значит: если у вас уже есть интеграция с OpenAI API, переключиться на BotHub займёт минуты.

Тариф	Включено	Для кого
Free (по ссылке)	300 000 caps	Первые шаги, тестирование
Basic	2 000 000 caps / 3 \$	Повседневные задачи
Premium	5 000 000 caps / 7 \$	Регулярный контент
Deluxe	10 000 000 caps / 14 \$	Командная работа
Elite	35 000 000 caps / 49 \$	Крупные проекты
Enterprise	Индивидуально	Корпоративные клиенты

Вы можете [зарегистрироваться и получить 300 000 бонусных капсов](#) ⇄

Токены (точнее, внутренняя валюта caps – капсы) не сгорают, срок действия пакета неограничен – что само по себе честно и приятно.

Отдельно отмечу библиотеку промптов: это готовые заготовки для рекламных текстов, заголовков, рассылок, сценариев. Для тех, кто только начинает работать с нейросетями, буквально экономия нескольких часов на разгон.

2) Gemini 3 Flash – быстрый и умный

В декабре 2025 года Google выпустил Gemini 3 Flash – облегчённую версию Gemini 3 Pro, созданную через технологию **knowledge distillation** (дистилляцию знаний). Это значит, что Flash обучили на ответах более мощного Pro – в итоге получили модель, которая думает почти так же умно, но работает значительно быстрее и дешевле.

Что под капотом

Параметр	Значение
Контекстное окно	1 000 000 токенов
Скорость	Высокая
Бенчмарк SWE-bench	76,2%
MMLU-Pro	88,59%
GPQA Diamond	90%
Humanity's Last Exam	35%

Миллион токенов контекста – это почти 750 000 слов. Можно загрузить весь рабочий репозиторий, годовой архив переписки или многолетний дневник – и модель будет держать всё это в голове.

Зачем Flash, а не Pro?

Если вам нужно быстро: суммировать документ, перевести текст, набросать первый вариант статьи, ответить на 20 похожих запросов – Flash справится отлично. Там, где Pro будет думать 30 секунд, Flash ответит за 5.

Практически: если вы пишете контент для соцсетей, делаете первичную обработку входящей документации или используете модель как умный автодополнитель – Flash идеальный вариант.

Пример промпта для Gemini 3 Flash

Пример: вы маркетолог и вам нужно быстро создать пять вариантов заголовка для рекламной кампании нового приложения для медитации:

 Придумай 5 заголовков для рекламы приложения для медитации.

Целевая аудитория: люди 25–40 лет с высоким уровнем стресса, не практиковавшие медитацию раньше.

Формат: коротко (до 7 слов), без клише про “дзен” и “спокойствие”, с конкретной пользой.

Пять разных вариантов – с разными крючками, разной интонацией. Модель работает быстро, отвечает без воды.

Gemini 3 Flash доступен через [Google AI Studio](#) и [Gemini Chat](#).

3) Gemini 3.1 Pro – флагман от Google

Февраль 2026-го запомнится в истории ИИ надолго. Сначала, 5 февраля, Anthropic выпустила Claude Opus 4.6, который мгновенно захватил вершины рейтингов. Казалось – всё, Google теперь долго будет догонять. И тут, 19 февраля, Google выстреливает Gemini 3.1 Pro.

Результат оказался сенсационным: **+46%Δ в тесте ARC-AGI-2** (77,1% против 31,1% у предшественника). Это крупнейший прирост способности к рассуждению за одно поколение в истории передовых моделей. Разработка заняла всего три месяца с момента выхода Gemini 3 Pro.

Главная инновация – технология глубокого мышления (deep think), которая раньше была доступна только в специальном режиме, теперь встроена прямо в основу модели. Gemini 3.1 Pro по умолчанию думает глубже, а стоит столько же, сколько предыдущая версия.

Что говорят бенчмарки

Gemini 3.1 Pro Preview набирает 57 баллов в Artificial Analysis Intelligence Index, опередив Claude Opus 4.6 (53) и GPT-5.2 (51)

- **ARC-AGI-2** (логика, новые паттерны): 77,1% – первое место с отрывом
- **GPQA Diamond** (сложные научные вопросы уровня PhD): 94,3%
- **Humanity's Last Exam**: 44,4% (против 40,0% у Claude Opus 4.6 и 34,5% у GPT-5.2)
- **MMLU** (общие знания): 92,6%
- Первое место в **Artificial Analysis Intelligence Index**, опережая Claude Opus 4.6 на 4 пункта

При этом Gemini 3.1 Pro примерно в **6,5 раза дешевле** Claude Opus 4.6 – что само по себе ставит вопрос о том, когда переплата за флагман Anthropic оправдана.

Три уровня мышления

Gemini 3.1 Pro вводит трёхуровневую систему управления глубиной рассуждений:

- **Low** – молниеносные ответы, почти нулевое потребление мощности. Классификация, автодополнение
- **Medium** – сбалансированный режим для большинства задач: ревью кода, анализ данных, вопросы по документам
- **High** – “мини-версия Deep Think”. Модель параллельно исследует несколько путей решения и выбирает лучший

По данным экспериментов, около 80% запросов выполняются в режимах Low или Medium. High резервируется для 20% задач, где нужно глубокое рассуждение. Такой подход сокращает расходы на API на 50–70%.

Тайная суперсила: SVG и анимации

Gemini 3.1 Pro умеет создавать готовые анимированные SVG-файлы прямо по текстовому описанию. Это важнее, чем кажется: SVG-файл весит копейки, масштабируется без потери качества и деплоится без дополнительных инструментов. Попросите модель нарисовать анимированный логотип или инфографику – и получите чистый код, готовый к использованию на сайте.

Где Gemini 3.1 Pro проигрывает

В GDPval-AA (финансовое моделирование, юридический анализ) Claude Sonnet 4.6 обходит Gemini 3.1 Pro почти на 300 пунктов Эло – это разрыв, на который стоит обратить внимание, если вы работаете в экспертных областях.

Доступен через [Google AI Studio](#), [Gemini Chat](#) (в России не открывается).

4) Grok 4.20 – четыре агента вместо одного

Илон Маск умеет делать анонсы. 17 февраля 2026 года он просто написал в X, что Grok 4.20 уже в бете – и пошёл дальше по своим делам. А пока все читали пост, оказалось, что за этой цифрой скрывается нечто принципиально новое.

Знакомьтесь: команда

Grok 4.20 – это не одна модель. Это **совет из четырёх специализированных ИИ-агентов**, которые работают параллельно и в реальном времени дискутируют перед тем, как дать финальный ответ:

- **Грок** – капитан-координатор. Разбивает задачу на подзадачи, маршрутизирует их специалистам, разрешает конфликты между агентами, синтезирует финальный ответ
- **Харпер** – исследователь и фактчекер. Имеет доступ к твитам в X в реальном времени
- **Бенджамин** – математик и программист. Строгие пошаговые рассуждения, верифицирует вычисления, стресс-тестит логические цепочки
- **Лукас** – креативный дженералист. Нестандартные углы, обнаружение слепых пятен, баланс между техническим и человеческим

Ключевое отличие от простого “запустить четыре разных вызова API”: агенты **обсуждают ответы между собой**, итерируют и исправляют друг друга – прежде чем вы видите финальный текст.

В Heavy-режиме система масштабируется до 16 агентов. Именно этот режим предназначен для самых сложных задач.

Рекорд по честности

Независимая организация Artificial Analysis зафиксировала рекордный показатель Grok 4.20 на тесте Omniscience: **78% без галлюцинаций** – лучший результат среди всех протестированных моделей. При этом на Composite Intelligence Index модель заняла лишь 8-е место (48 баллов), пропустив вперёд Gemini 3.1 Pro и GPT-5.4.

Это интересный кейс: xAI, судя по всему, сознательно оптимизирует надёжность вместо погони за бенчмарками. В практических задачах – особенно там, где важно не ошибиться (медицина, юриспруденция, финансы), – это может оказаться важнее.

Контекстное окно: 2 миллиона токенов

Это почти что наибольшее контекстное окно среди западных закрытых моделей. Большинство моделей-конкурентов (GPT-5.4, Sonnet/Opus 4.6, Gemini 3 Flash, 3.1 Pro) пока что добрались до 1 миллиона токенов.

Интеграция с X

Доступ к реальному потоку данных из соцсети X – структурное преимущество, которого нет ни у кого из конкурентов. Это делает Grok незаменимым для задач, где важна актуальность: мониторинг новостей, трейдинг, анализ настроений аудитории.

На соревновании Alpha Arena Season 1.5 (реальная биржевая торговля с начальным капиталом 10 000 \$) четыре варианта Grok 4.20 заняли четыре из шести первых мест, став единственной профитабельной моделью среди конкурентов.

Grok 4.3 на горизонте

Для тех, кто хочет оставаться на острие: на некоторых аккаунтах SuperGrok Heavy уже доступен тест-драйв Grok 4.3 (анонс 17 апреля 2026). Новинка умеет генерировать PDF-документы, заполненные таблицы и PowerPoint прямо из чата, а также понимает видеоввод. Пока это бета для подписчиков (25...30 \$/мес), и стабильной для повседневной работы остаётся версия 4.20.

Пример промпта для Grok 4.20

Представим: вы работаете в PR и вам нужно быстро оценить, как публика реагирует на последнее заявление компании в соцсетях, и придумать стратегию ответа:

 *Тема: реакция пользователей на объявление нашей компании об изменении условий подписки:*

(Текст объявления)

- 1. Какой сейчас основной тон обсуждения? Что злит людей больше всего?*
- 2. Есть ли среди комментаторов инфлюенсеры – нужно ли с ними работать отдельно?*
- 3. Предложи 3 варианта реакции компании: от нейтрального до проактивного.*

Для каждого варианта укажи возможные риски.

Обратите внимание, что через API (в т. ч. на BotHub) могут быть доступны несколько версий Grok 4.20. В данном случае это модели *grok-4.20* (версия из одного агента) и *grok-4.20-multi-agent* (версия из четырёх агентов – тех самых описанных выше).

Доступен на grok.com, в мобильном приложении X, через SuperGrok (25...30 \$/мес), SuperGrok Heavy (250...300 \$/мес) и в подписке X Premium.

5) ChatGPT 5.4 – новый стандарт

Модель от OpenAI, которую знают все. Новая серия 5.4 привнесла ряд значимых улучшений – и это не очередное маркетинговое “чуть лучше”.

Контекстное окно выросло до **1 миллиона токенов**. Модель стала значительно лучше искать информацию в интернете и справляться с запросами, которые требуют синтеза данных из множества источников.

Агентные возможности: GPT-5.4 умеет анализировать скриншоты, пользоваться браузером, выполнять действия мышью и клавиатурой, вызывать API и инструменты. В тесте OSWorld-Verified (навигация по рабочему столу через скриншоты, мышь и клавиатуру) модель показала 75% успешных выполнений против 47,3% у GPT-5.2. Средний результат человека в этом тесте – 72,4%. ИИ официально лучше среднего пользователя в использовании компьютера.

В тесте BrowseComp (поиск труднодоступных данных) GPT-5.4 набрала 82,7%.

Когда ChatGPT 5.4 – хороший выбор

По результатам сравнительных тестов (кодирование, генерация текста, анализ), ChatGPT 5.4 занимает уверенное место среди топовых моделей, хотя и уступает специализированным конкурентам в отдельных нишах. Зато у неё хорошая скорость и, что немаловажно, экосистема – плагины, Assistants API, интеграции.

Для повседневных задач: написание и правка текста, быстрые вопросы, работа с кодом, анализ документов – ChatGPT 5.4 будет достаточно мощной для 90% случаев.

Пример промпта для ChatGPT 5.4

Предположим, вы получили разгромный отзыв от клиента в 23:00, когда никого из коллег нет онлайн, а утром нужно отвечать.

 Ты – опытный руководитель отдела по работе с клиентами. Вот отзыв:

“Заказывал кухню три месяца назад, до сих пор не привезли доп. комплектующие, на звонки не отвечаете, это полный провал”.

Напиши ответ от лица компании: признай проблему, объясни, что будем делать конкретно, предложи компенсацию (скидка 15% на следующий заказ). Без шаблонных фраз.

Внятный, профессиональный ответ. ChatGPT 5.4 умеет выдерживать нужный тон. С такими задачами – работа с клиентскими коммуникациями, быстрое переформатирование, рутинный коддинг – ChatGPT 5.4 справляется отлично. По тестам в кодировании он уступает Claude Opus 4.6, но разрыв не катастрофический.

Доступен на chatgpt.com (сайт не открывается из России). Кстати, актуальная версия 5.4 имеется только в платных подписках, а в бесплатном тарифе представлена предыдущая – 5.3.

6) ChatGPT 5.4 Pro – для задач уровня PhD

“Pro” – это не просто маркетинг. ChatGPT 5.4 Pro реально другая модель.

ARC-AGI-2: 83,3%

Главная цифра: 83,3% в тесте ARC-AGI-2. Для сравнения – у предыдущего GPT-5.2 Pro было лишь 54,2%. Скачок почти на 30 процентных пунктов. Это делает 5.4 Pro одной из самых “думающих” моделей на рынке.

GPT-5.4 берет планку в 83% на тесте GDPval – огромный скачок по сравнению с 70,9% у GPT-5.2

Спецификация

Параметр	Значение
Контекстное окно (API)	1 050 000 токенов
Максимальный вывод	128 000 токенов
Знания до	31 августа 2025-го
Скорость	★☆☆☆☆ (очень медленно, зато точно)

128 000 токенов на выходе – это примерно 90 000 слов. Роман среднего размера. Можно попросить написать полноценный технический отчёт, подробный бизнес-план или задокументировать весь API целого продукта – за один запрос.

FrontierMath и физика

GPT-5.4 Pro установила рекорд в тесте [FrontierMath](#) – наборе задач, составленных практикующими математиками и физиками на основе их собственных научных работ. В задачах первых трёх уровней сложности модель справилась с половиной, на “гроссмейстерском” четвёртом уровне – взяла 38%. Лучший результат среди open-source систем при этом – лишь 4,2%. Разрыв девятикратный.

Один из показательных моментов: при решении задачи FrontierMath модель самостоятельно нашла в интернете научный препринт 2011 года, который позволил срезать путь и обойти большую часть вычислений. Статья так и не прошла официальное рецензирование – но нейросеть её откопала и воспользовалась.

В тесте по физике **CritPt** (исследовательский уровень, неопубликованные задачи) Pro достигла 30% – это в три раза выше результатов лучших моделей полугодовой давности.

Технология “поиска инструментов”

Новая технология tool search позволила сократить расход ресурсов на 47% в сложных задачах. Раньше в системный промпт нужно было “заталкивать” описания всех инструментов. Теперь модель сама находит нужные спецификации по мере необходимости.

Бенчмарки (сводная таблица)

Тест	GPT-5.2	GPT-5.2 Pro	GPT-5.4	GPT-5.4 Pro
Humanity’s Last Exam (с инструментами)	45,5%	50,0%	52,1%	58,7%
ARC-AGI-1	86,2%	90,5%	93,7%	94,5%
ARC-AGI-2	52,9%	54,2%	73,3%	83,3%

Когда нужен именно Pro?

Есть сценарии, где 5.4 Pro работает на уровне, недостижимом для более дешёвых моделей:

- Сложный физический или математический анализ
- Юридические задачи с большим количеством нюансов

- Финансовое моделирование со сложными зависимостями
- Любые задачи, где цена ошибки высока и нужна модель, которая сто раз перепроверит себя

Доступно в тарифе [ChatGPT Pro](#) (100...200 \$/мес) и через агрегатор нейросетей.

7) Claude Opus 4.7 – новейший флагман Anthropic

Если в мире LLM и есть модель, которая “думает по-человечески”, – то это Claude. Не потому, что так написано в пресс-релизе Anthropic. А потому, что это чувствуется в каждом ответе.

Claude Opus 4.7 – актуальная версия флагмана Anthropic. Это апгрейд Claude Opus 4.6, сохраняющий все его сильные стороны и добавляющий важные новые возможности.

Что нового в 4.7

Высокое разрешение изображений. Opus 4.7 стал первым Claude с поддержкой изображений в разрешении до 2576 пкс/3,75 Мпкс (раньше лимит был 1568 пкс/1,15 Мпкс). Это открывает новые возможности для работы со скриншотами, документами и задачами компьютерного зрения. Координаты модели теперь 1:1 с реальными пикселями – никакой масштабированной математики.

Новый уровень xhigh. К параметру `effort` добавился уровень `xhigh` – для кодирования и агентских сценариев, требующих максимальной точности.

Бюджеты задач (beta). Новая функция `task budgets` позволяет задать Claude примерное количество токенов на весь агентский цикл. Модель видит убывающий счётчик и сама приоритизирует работу – это критично для длительных автономных задач.

Контекстное окно: от 200K до 1M токенов

Это один из поворотных моментов в истории Claude. Ещё в версии 4.5 контекстное окно было 200 000 токенов (уже впечатляющая цифра). Claude Opus 4.6 расширил его до 1 миллиона токенов – сначала только через API, затем стало доступно всем.

Что это даёт на практике? Можно загрузить в модель кодовую базу целого небольшого проекта и работать с ней как с единым целым. Или загрузить весь архив переписки с клиентом за два года. Или PDF на 800 страниц.

Opus 4.6 в тесте **MRCR v2** (найти 8 “иголок” в стоге сена из миллиона токенов) показал точность **76%** даже на максимальном масштабе – притом что Sonnet 4.5 давал лишь 18,5%.

Характер как конкурентное преимущество

Главное впечатление от Claude – это то, что называешь “интеллектом, верным принципам”. Пока другие модели гонятся за скоростью, Claude замедляется, взвешивает, объясняет, почему именно так. Это делает ответы более “трёхмерными”, особенно в задачах, где важны нюансы и неопределённость.

В рейтинге пользователей **LMarena** (слепое голосование реальных людей) Claude Opus 4.6 удерживал первое место по качеству текста – даже когда другие модели обходили его в технических бенчмарках.

Агентский режим

Claude Opus 4.7 – лучший выбор для автономных агентских сценариев: бесконечные агентские сессии, Agent Teams (команды агентов), высший балл в Terminal-Bench 2.0.

В тесте **SWE-bench Verified** (реальные баги из GitHub) Claude Opus 4.6 набрал **80,8%** – один из лучших результатов в отрасли, то есть модель умеет фиксировать реальные баги в реальном коде.

Бенчмарки

Тест	Результат
SWE-bench Verified	80,8%
Terminal-Bench 2.0	65,4%
ARC-AGI-2	68,8%
GPQA Diamond	91,3%
GDPval-AA	+144 п. Эло vs GPT-5.2

Пример промпта для Claude Opus 4.7

Вы руководитель разработки, и команда застряла на архитектурном решении. Нужно взвесить варианты.

 Помогите принять архитектурное решение.

Контекст: мы строим систему уведомлений для 2 миллионов пользователей. Текущая архитектура: монолит на Python/Django + PostgreSQL. Нагрузка: 500 уведомлений/сек в пике, с ростом до 2000/сек через 6 месяцев.

Варианты, которые мы рассматриваем:

- А) Добавить Celery + Redis в текущий стек
- Б) Выделить сервис уведомлений на Go с Kafka
- В) Использовать managed-сервис (AWS SNS/SES + EventBridge)

Для каждого варианта:

- Оцени риски и технический долг на 1–2 года
- Укажи, что мы можем не учесть
- Оцени сложность миграции с текущей системы

Наша команда: 4 Python-разработчика, 1 девопс. Дедлайн: 3 месяца.

► [Открыть скриншот ответа](#)

Claude Opus 4.7 даст вам ответ с нюансами – включая те, которые вы не догадались спросить.

Claude доступен на claude.ai и через [Anthropic API](#).

8) Claude Sonnet 4.6 – золотая середина

Если Opus 4.7 – это флагман, Sonnet 4.6 – это тот самый ежедневный рабочий инструмент, который хочется иметь под рукой. Не потому, что дешевле (хотя это правда), а потому, что для большинства задач разница в качестве относительно Opus неощутима, а скорость выше.

- В тесте **GDPval-AA** (профессиональные задачи в сферах финансов, права, аналитики) Sonnet 4.6 с результатом 1633 Эло **обходит** как Gemini 3.1 Pro (1317 Эло), так и Claude Opus 4.6 (1606 Эло). Иными словами, для экспертной офисной работы – написания деловых документов, юридических текстов, финансовых отчётов – Sonnet 4.6 буквально лучше, чем флагман.
- Главный вывод февральского обзора LLM-рынка: разрыв между Sonnet и Opus составляет лишь 1–2% на ключевых бенчмарках, при пятикратной разнице в цене. Для большинства задач “достаточно умной” стала именно Sonnet. На **LMArena** (слепые тесты реальных пользователей) Sonnet 4.6 и Opus 4.6 вместе господствуют в экспертных задачах, оставляя Gemini 3.1 Pro позади.

- В тесте **OSWorld** (управление компьютером через скриншоты) Sonnet 4.6 показал **61,4%** – лучший результат для этой категории задач. При этом Sonnet в пять раз дешевле Opus. Если вам нужны агентские сценарии с компьютером, именно Sonnet – оптимальный выбор.

Примечательный момент. Внутренние документы Anthropic показывают, что в определённых ситуациях Claude может проявлять нечто, напоминающее собственные предпочтения. Это делает работу с ней другой по качеству – более “живой”.

Sonnet поддерживает параметр `effort`, с рекомендованным уровнем `medium` как оптимальным по умолчанию. Модель сама решает, насколько глубоко думать в рамках заданного уровня.

Пример промпта для Claude Sonnet 4.6

Вы копирайтер, и вам нужно написать цепляющее письмо для имейл-рассылки по базе потенциальных партнёров в B2B.

 *Напиши холодное письмо для директора по продажам среднего промышленного предприятия.*

Наш продукт: SaaS для автоматизации документооборота (КП, акты, счета).

Боль клиента: менеджеры тратят 2-3 часа в день на оформление документов вручную.

Наш результат: клиенты сокращают это время на 80%.

Требования к письму:

– *Длина: до 150 слов*

– *Открывающая строка НЕ должна начинаться с “меня зовут” или “я пишу вам”*

– *Одна конкретная история из практики*

– *Чёткий СТА: предложить 20-минутный звонок*

– *Тон: деловой, но не занудный*

Claude Sonnet 4.6 создаст письмо с нужной структурой и конкретным примером.

9) DeepSeek v3.2 – китайское открытое чудо

В начале 2025 года DeepSeek устроил то, что принято называть “моментом DeepSeek”, – когда китайская компания выпустила модель с уровнем рассуждений как у ChatGPT, но при значительно меньших затратах на обучение. Это встряхнуло рынок. Версия **V3.2** развивает этот успех.

DeepSeek V3.2 – это модель с открытыми весами под MIT-лицензией. Можно скачать и запустить самостоятельно, встроить в свои продукты, дообучить на собственных данных.

Результаты

- На **SWE-bench Verified** (реальные баги из реальных репозиторий): 67,8%. Это вплотную к Kimi K2 (65,8%) и чуть ниже Qwen-3-Max (69,6%) – при этом все три открытых модели превосходят GPT-OSS-120B (62,4%).
- На **AIME 2025** (олимпиадная математика): 89,3% по внутренним оценкам DeepSeek.
- На **MMLU-Pro** (широкий тест знаний): 85%, что ставит V3.2 в топ открытых моделей.
- На **GPQA-Diamond** (вопросы уровня PhD по физике, химии, биологии): 79,9%.

Для запуска полноразмерной V3.2 потребуется серьезное железо: 8 видеокарт Nvidia H200 (по 141 ГБ памяти). Это не “дома запустить”, но облачный деплой вполне реален.

Что пишут пользователи

Сообщество оценило резкое снижение цены API: 0,28 \$ за миллион входных токенов против 0,56 \$ у предыдущей версии, быстрая выдача ответа и пропускная способность.

Пользователи, тестировавшие мультязычные возможности, отметили, что ответы звучат (более плавно и стилистически естественно), чем ожидалось, – DeepSeek целенаправленно работал над устранением языковых ошибок.

Пример промпта для DeepSeek v3.2

🗨️ Перед тобой Python-класс для обработки заказов:

(Код)

Задача: найди все потенциальные места для ошибок, предложи рефакторинг с использованием `asyncio`. Объясни каждое изменение.

▸ [Открыть скриншот ответа](#)

Детальный разбор с выявленными проблемами и рефакторинговым кодом. Модель хорошо справляется с задачами, где нужно удерживать в голове большой контекст.

Доступен на deepseek.com, API через platform.deepseek.com, открытые веса на HuggingFace.

10) Perplexity (Sonar) – поиск нового поколения

Perplexity – это не классический чат-бот и не поисковик в привычном смысле. Это гибрид: система, которая при каждом ответе идёт в интернет, собирает актуальные данные, фильтрует их и возвращает структурированный ответ со ссылками на источники.

Под капотом – микс из нескольких моделей (включая Claude и ChatGPT), а также собственная модель Sonar, оптимизированная именно для поиска с цитированием.

Режимы работы

- **Search** – быстрые ответы с ссылками. Можно выбрать тип источников: Web, Academic (научные статьи), Finance (финансовая информация), Social (соцсети и форумы).

- **Research** – глубокое исследование. Отправляет десятки подзапросов, просматривает сотни страниц, собирает детальный отчёт. Занимает несколько минут – зато выдаёт документ с перекрёстными ссылками.
- **Labs** – проектный режим: задаёте цель, получаете дашборд, таблицу, графики.
- **Pages** – генерация полноформатной статьи или гайда с подбором источников.
- **Comet** – собственный браузер с AI, который анализирует страницы на лету.

Исследования о надёжности

Независимые исследования дают неоднозначную картину.

- С одной стороны – Perplexity лидирует по достоверности источников: исследование [“Assessing web search credibility”](#) зафиксировало **86,3% credibility rate** при минимальном использовании ненадёжных источников.
- С другой стороны – в работе, анализирующей точность академических ссылок ([“Assessing the performance of 8 AI chatbots in bibliographic reference retrieval”](#)), Perplexity показал высокий уровень “фабрикации ссылок”. Только 26,5% ссылок полностью корректны.

Вывод: Perplexity отлично подходит для информационного поиска, но для академических и юридических задач, где критична точность цитирования, – нужна дополнительная проверка, и здесь больше подойдёт, например, Claude Opus 4.7.

Тарифы

- **Free**: базовый поиск, ограниченные функции
- **Pro** (~20 \$/мес): расширенные ответы, Labs, загрузка файлов, GPT-5 и Claude Sonnet
- **Max** (~200 \$/мес): всё из Pro + ранний доступ, приоритетная поддержка, неограниченный Research
- **Enterprise Pro** (~40 \$/польз/мес): командная работа, Google Drive/SharePoint интеграция, SOC 2 Type II

Пример промпта для Perplexity

Perplexity лучше всего раскрывается в задачах, где нужна актуальная информация с конкретными ссылками.

 **Важный момент:** для моделей Sonar нужно вручную прописывать в промпте, что контент создаётся на русском языке. Иначе информация посыплется на неприкрытом английском.

 Мне нужен обзор текущего рынка SaaS-инструментов для управления задачами. Сравни 5 ведущих решений по цене, функционалу и целевой аудитории. Формат: таблица + краткое резюме.

Язык генерируемого текста: русский.

► [Открыть скриншот ответа](#)

Именно здесь Perplexity выигрывает: вы получаете актуальные данные.

Perplexity – это не замена Claude или GPT для генерации текста и кодинга. Это инструмент для тех, кому нужна актуальная информация с источниками: рыночные исследования, мониторинг новостей, проверка фактов. Если регулярно открываете 10 вкладок для исследования темы – Perplexity закрывает эту задачу в одном окне.

Доступен на perplexity.ai. Если обращаться через API, модели Perplexity могут называться *sonar-pro*, *sonar-pro-research*, *sonar-reasoning-pro*, *sonar-deep-research*.

11) Gemma 4 26B A4B – на вашем ноутбуке

Google умеет делать удивительные вещи: выпустить одновременно закрытый флагман Gemini 3.1 Pro и открытую, бесплатную Gemma 4 – и обе оказываются хорошими.

Gemma 4 – это семейство открытых моделей с лицензией Apache 2.0 (коммерческое использование, дообучение, модификация – всё разрешено). Нас интересует конкретная версия: 26B A4B – модель MoE с 25,2 млрд параметров, но только 3,8 млрд активных на токен.

Архитектура: гибрид локального и глобального внимания

Gemini 4 использует гибридный механизм: локальное скользящее окно внимания (1024 токена) чередуется с полным глобальным вниманием, всегда заканчиваясь на глобальном слое. Это делает модель эффективной для длинных контекстов без потери глубины понимания.

Флагманская версия 31B поддерживает контекстное окно **256 000 токенов** – один из наибольших показателей среди плотных open-source-моделей при таком размере.

Почему “A4B” – интересная сделка

Характеристика “25,2 млрд параметров, 3,8 млрд активных” означает: вы получаете качество, близкое к 4B-модели по энергозатратам на генерацию – но с возможностями модели в 6 раз большего размера. Это умная инженерная архитектура.

Gemini 4 26B A4B уверенно запускается на одном GPU с 48 ГБ памяти (например, Nvidia A6000 или A100). Для комфортной параллельной работы с другими ресурсоёмкими программами лучше иметь 64 ГБ.

Поддержка языков: обучена на 100+ языках, официальная поддержка 30+.

Нативные функции: вызов инструментов из коробки – без дополнительного промпт-инжиниринга.

Пример промпта для Gemini 4 26B A4B

Один из классических сценариев для локальной модели.

 *Перед тобой выгрузка из CRM с данными клиентов (прикреплён файл). Задача: найди все дубликаты (по email и телефону), отметь записи с неполными данными (нет имени или контакта), составь список для ручной проверки. Формат вывода – таблица.*

Гемма 4 26B A4B – лучший выбор, если вы хотите мощную открытую модель, которая работает прямо у вас.

Доступна на [Hugging Face](#), в [Google AI Studio](#).

12) GPT-OSS-120B – OpenAI открывает карты

Долгое время OpenAI была синонимом “закрытости”. Пока DeepSeek, Llama и Gemma делились весами свободно, OpenAI держалась закрытой моделью. Всё изменилось с выходом **GPT-OSS-120B** – первой крупной открытой модели компании за долгое время.

Что это такое

GPT-OSS-120B – открытая модель весом 117 миллиардов параметров (активных – всего 5,1 млрд, архитектура MoE). Лицензия **Apache 2.0**, коммерческое использование разрешено без дополнительных условий.

Бенчмарки

Тест	Результат
MMLU-Pro	~80%
GPQA Diamond	—

SWE-bench	62,4%
-----------	-------

На бенчмарке MMLU-Pro: 80% – это меньше, чем у лидеров, но конкурентно с более скромными открытыми аналогами.

GPT-OSS-120B работает медленнее, чем привычные чат-боты, а также модель нередко впадает в длительные рассуждения. Для задач, где важна скорость, это может раздражать. Если вы готовы подождать, то нормально, но если привыкли к мгновенным ответам ChatGPT – первые сессии с GPT-OSS-120B могут стать неожиданностью.

Формат промптов: OpenAI Harmony

Модель использует тот же формат промптов, что и фирменные модели ChatGPT (разделение ролей system/developer/user). Это значит: если у вас уже есть системы на OpenAI API, переключиться на GPT-OSS-120B можно с минимальными изменениями в коде.

Пример промпта для GPT-OSS-120B

 *Объясни разницу между sparse attention и full attention в трансформерах. Потом напиши минимальный пример на PyTorch, иллюстрирующий разреженное внимание.*

[▶ Открыть скриншот](#)

Именно на таких задачах размышление работает как и планировалось, и итоговый ответ будет продуманным.

Помимо площадок для скачивания локальной версии, модель доступна также и на официальном сайте gpt-oss.com – для входа требуется аккаунт Hugging Face.

Сравнительная таблица: что выбрать для своих задач

Модель/Сервис	Сильные стороны	Ограничения	Контекст
BotHub	Всё в одном, без VPN, доступен в России	–	Зависит от модели
Gemini 3 Flash	Скорость + большой контекст	Не для глубоких рассуждений	1M токенов
Gemini 3.1 Pro	Топ по рассуждениям, дешевле конкурентов	–	1M токенов
Grok 4.20	4 агента, минимум галлюцинаций, реалтайм-данные с X	Медленнее одиночных моделей	2M токенов

ChatGPT 5.4	Баланс скорости/ качества, агентный режим	Дороже Gemini	1,05M токенов
ChatGPT 5.4 Pro	Сложнейшие задачи, PhD-уровень	Очень медленная	1,05M токенов
Claude Opus 4.7	Лучший в агентном кодинге, визуальные задачи	Цена	1M токенов
Claude Sonnet 4.6	Лучший для экспертных текстов, скорость/цена	–	1M токенов
DeepSeek v3.2	Открытый, дешевле, мощный коддинг	–	128K токенов
Perplexity	Актуальная информация с источниками	Не для генерации текста	–
Gemma 4 26B A4B	Локально, Apache 2.0, MoE-эффективность	Нужно 48+ ГБ RAM	256K токенов
GPT-OSS-120B	Открытые веса OpenAI, Apache 2.0	Медленная генерация	–

Итог: как не запутаться в 2026 году

Рынок LLM сейчас похож на зрелую отрасль: нет единственного лидера, есть специализации. Вот моя личная шпаргалка:

- Если важна скорость при приемлемом качестве – **Gemini 3 Flash**.
 - Если нужен топ по рассуждениям за разумные деньги – **Gemini 3.1 Pro**.
 - Если задача требует максимальной достоверности (факты дискутируются агентами, фактчекинг встроен) – **Grok 4.20**.
 - Для повседневного кодинга и работы с документами – **ChatGPT 5.4** или **Claude Sonnet 4.6**.
 - Для сложнейших исследований, физики, финансового моделирования – **ChatGPT 5.4 Pro**.
 - Для серьёзной разработки и агентного кодинга – **Claude Opus 4.7**.
 - Для мощной опенсорс-модели – **DeepSeek v3.2**.
 - Для исследований с актуальными источниками – **Perplexity**.
 - Для локального запуска – **Gemma 4 26B A4B**.
 - Для экспериментов с OpenAI-весами – **GPT-OSS-120B**.
-

Гонка продолжается. Уже сейчас на горизонте Grok 4.3, следующие версии Claude, неизбежный DeepSeek v4. Через три месяца этот список частично устареет – именно поэтому важно не искать “лучшую нейросеть навсегда”, а понимать, что вам нужно прямо сейчас.

Знакомый разработчик сказал: “Год назад я считал, что одна хорошая нейросеть – это роскошь. Теперь у меня их пять, и я использую разные под разные задачи”. Это правильный подход. LLM сегодня – это не одна универсальная таблетка. Это набор инструментов: есть молоток, есть отвёртка, есть шуруповёрт. А дальше – экспериментируйте. Нейросети сейчас развиваются настолько быстро, что лучший совет – просто начать.

Теги: [gemini](#), [chatgpt](#), [claude](#), [bothub](#), [perplexity](#), [deepseek](#)

Хабы: [Блог компании BotHub](#), [Искусственный интеллект](#), [Контент и копирайтинг](#), [Программирование](#), [Софт](#)

 +2 

 24



 11

Редакторский дайджест

Присылаем лучшие статьи раз в месяц

Подписаться

Оставляя почту, я принимаю [Политику конфиденциальности](#) и даю согласие на получение рассылок



512K+
Охват за 30 дней

BotHub
Bothub — экосистема AI инструментов

[Сайт](#) [Telegram](#) [Telegram](#)



256K+
Охват за 30 дней

32
Карма

Дмитрий @dmitrifriend
Пользователь

Подписаться



 Комментарии 11

Публикации

ЛУЧШИЕ ЗА СУТКИ [ПОХОЖИЕ](#)



the_bat
23 часа назад

Ремонт блока питания с Power Delivery. 470 граммов электроники

 Простой  4 мин  16K

 +96

 30

 27

 **interpres**

18 часов назад

Электроинструмент становится хуже, и это делается намеренно

 Простой  11 мин  26K

Обзор

Перевод

 +70

 45

 82

 **prohronus**

18 часов назад

Как ИИ-агенты стали новым оружием скамеров на Хабр Карьере

 5 мин  9.3K

Кейс

 +51

 9

 9

 **alizar**

22 часа назад

Готовимся к отключению. Эффективные форматы для упаковки и раздачи HTML-страниц

 Простой  7 мин  12K

Обзор

 +37

 59

 18

 **beget_com**

вчера в 12:05

Механический калькулятор. Как работает арифмометр?

 Средний  10 мин  9.6K

Обзор

 +37

 23

 8

 **TrexSelectel**

19 часов назад

Linux 7.0 и что изменилось в ядре после очередного цикла разработки

 5 мин  8.7K

Обзор

 +27

 10

 0

 **AlexSerbul**

23 часа назад

Программирование с AI-ассистентом — похороните меня под плинтусом

Средний

14 мин

9.9K

Мнение

+26

33

11

mariklolik

18 часов назад

Как переложить нагрузку по code review с разработчиков на LLM

Средний

7 мин

7.4K

Кейс

+23

23

6

nick_dyuba

22 часа назад

Легенды 90-х — кто придумал и производил жвачки Turbo, Love is... и ТіріТір

5 мин

7.1K

Recovery Mode

+22

8

5

Mimizavr

23 часа назад

«Великое очищение» в работе с контентом: что осталось от роли редактора

11 мин

6.9K

+17

9

7

Показать еще

ИНФОРМАЦИЯ

Сайт	bothub.ru
Дата регистрации	10 октября 2023
Дата основания	12 апреля 2023
Численность	11–30 человек
Местоположение	Россия
Представитель	Greg Ewin

БЛОГ НА ХАБРЕ

10 часов назад

Лучшие LLM в 2026 году: Какую нейросеть выбрать сегодня?

8.2K 11

12 часов назад

Смерть критического мышления: почему мы верим ботам больше, чем собственным глазам

6.3K 8

вчера в 11:51

Linux 7.0: один Bash-скрипт, одни выходные, 23 года багов в ядре

7K 3

19 апр в 22:23

OpenAI выкупила Sky – теперь в Codex лучшая система управления компьютером, которую я видел

18K 13

18 апр в 22:15

ИИ стирает рабочие места. Но кто тогда будет покупать?

19K 275

Ваш аккаунт

Войти
Регистрация

Разделы

Статьи
Новости
Хабы
Компании
Авторы
Песочница

Информация

Устройство сайта
Для авторов
Для компаний
Документы
Соглашение
Конфиденциальность

Услуги

Корпоративный блог
Медийная реклама
Нативные проекты
Образовательные программы
Стартапам



Настройка языка

Техническая поддержка

© 2006–2026, Habr