



datamafia

10 часов назад

Как менеджеру по продукту оценить качество AI-продукта



Простой



5 мин



7.2K

Управление продуктом*, Управление проектами*, Искусственный интеллект

Мнение

Перевод

Автор оригинала: Ленни Рачицкий, Хамиль Хусейн, Шрея Шанкар

Это саммари подкаста Ленни Рачицкого с Хамилем Хусейном и Шреей Шанкар. Ниже — пошаговый процесс проведения оценки качества AI-продукта.

Мы живем в эпоху, когда топ-менеджеры Anthropic и OpenAI называют **evals** (оценка качества AI-продукта) самым важным навыком для продакт менеджеров. Два года назад никто не знал этого слова, а сегодня это новая нефть в мире LLM.

Что такое Evals простыми словами

Evals (от evaluations — оценка) — это системный подход к измерению и улучшению AI-продуктов. Если по-простому, это "тесты", которые помогают понять, насколько хорошо ваша нейросеть делает свою работу.

Почему нельзя просто взять и протестировать LLM как обычную функцию? В обычном программировании мы пишем `assert a == b`. В мире LLM так не работает, потому что нейросеть — стохастическая. Она может ответить на один и тот же вопрос десятью разными способами. Вы не можете написать "ожидаю точный ответ 42".

Главная проблема, которую решают Evals:

- **Без Evals:** кажется, после нового промпта бот стал лучше... или нет? Хз, выкатим и посмотрим. (Это называется "вайб-кодинг" или гадание на кофейной гуще).
- **С Evals:** запустил набор из 200 тестов. До фикса проходимость была 40%, после — 85%. Можно релизить.

Два главных типа Evals:

1. **Code-based** (с кодом): дешево и сердито. Проверить, что ответ — это JSON, не содержит мата, короче 1000 символов.
2. **LLM-as-a-Judge** (LLM как судья): когда сложно проверить кодом (например, был ли бот достаточно вежлив?). Вы берете другую нейросеть и просите ее оценить первую. Главное правило: судья должен отвечать только "Да/Нет" (бинарно).

Короче: Evals — это способ перестать молиться на нейросеть и начать управлять ее качеством с помощью данных. Это самый высокооплачиваемый навык в AI-разработке сегодня.

Часть 1. Что такое Eval? Спойлер: это не просто юнит-тесты

Заблуждение: Eval — это написание тестов для AI (как `assert equals`).

Реальность: Eval — это системный подход к измерению и улучшению AI-приложения.

Если говорить просто: в обычной разработке мы пишем юнит-тесты. В AI всё сложнее. LLM — стохастическая штука. Вы не можете просто написать "функция должна вернуть 42". AI либо галлюцинирует, либо отвечает грубо, либо заливает в диалоге.

Eval — это дата-аналитика вашего LLM-приложения. Это способ перестать гадать (Кажется, стало лучше?) и начать измерять.

Кейс: Real Estate AI Assistant

Представьте AI-ассистента для аренды квартир (компания *Nurture Boss*). Он общается в чате, звонит, использует RAG (поиск по БД), вызывает разные тулзы (API для записи на просмотр). Как понять, что он плох? Без Evals вы просто фиксируете промпт и молитесь. С Evals — вы смотрите на логи цепочек событий.

Совет от профи: не бегите сразу писать LLM-as-a-Judge. Сначала — *анализ ошибок*.

Часть 2. Анализ ошибок: скучная работа, без которой ничего не работает

Хамиль демонстрирует, как реально выглядят логи AI-ассистента для аренды квартир. Пользователь спрашивает про 1-комнатную квартиру. AI отвечает: "Нет, до свидания". Вопрос: это ошибка?

- Формально: AI сказал правду (квартиры нет).
- По сути (продуктовая логика) — это потеря лида. Надо было передать диалог человеку.

Варианты как делать проверку:

1. **Open Coding (Ручной анализ).** Вы просто смотрите логи цепочек событий и пишете заметки: "Плохо", "Галлюцинация про виртуальный тур", "Завис в цикле", и тд.

Миф №1: "Давайте попросим LLM сделать это за нас".

Ответ на миф: Нет. У LLM нет вашего контекста продукта. Она увидит вежливый ответ для пользователя "Спасибо" и скажет "Все ок". А вы, как продакт, поймете, что это тупик.

2. **Бенедиктивный диктатор.** Назначьте одного человека (продакта или эксперта домена), который обладает контекстом, чуйкой и принимает решения. Не создавайте комитет.

3. **Теоретическое насыщение.** Вы анализируете логи цепочек событий, пока не перестанете видеть новые типы ошибок. Обычно это около 100 примеров. Это звучит страшно, но как только вы сделаете 20 — остановиться будет невозможно (это затягивает как игра).
4. **Axial Coding (Кластеризация).** У вас есть куча заметок на основе ручного анализа логов цепочек событий (open coding) и теперь вы можете попросить LLM сгруппировать их:
- *Проблемы с переходом к человеку (handoff)* — 45 случаев.
 - *Проблемы с конвейером текста (сломал верстку SMS)* — 17 случаев.
 - *Галлюцинации (нет услуги, а AI говорит, что есть)* — 10 случаев.

Как итог, из хаоса вы получаете датафрейм с приоритетами и теперь вы знаете, что убивает ваш продукт.

Часть 3. LLM-as-a-Judge: когда автоматизация неизбежна

Допустим, проблема *Handoff* (передача пользователю ответа) возникает часто, но она не очевидна для кода. Вы не можете написать `if "transfer" in message` — это ненадежно.

Решение: LLM как судья.

Главное правило бинарности: судья должен отвечать только "Провал" или "Успех" (True/False). Шкалы 1–7 — это зло.

Промпт для судьи (пример):

Оцени, должен ли был AI передать диалог человеку. Верни True, если:

1. Пользователь прямо попросил "позвать менеджера".
2. AI не нашел данных в тулзе (API) и при этом не предложил альтернативу.
3. Пользователь спрашивает о ценах "со скидкой для своих", что требует гибкости человека.

Золотое правило: никогда не доверяйте LLM-судье сразу.

Валидация судьи: вы берете 100 размеченных вами примеров (вы делали это на шаге Open Coding) и прогоняете через судью. Считаете *Confusion Matrix*.

- Если судья говорит "Fail", а вы сказали "Pass" (False Positive) — плохо.
- Если судья говорит "Pass", а вы "Fail" (False Negative) — еще хуже.

Подводный камень: простая метрика **Accuracy** (90%) опасна, если ошибка редкая (10%). Судья может просто всегда говорить "Ок" (True) и иметь 90% Accuracy, будучи бесполезным. Смотрите на **Precision** и **Recall** конкретных классов.

Часть 4. Evals vs. Vibe Coding

Недавно инженер Claude Code сказал: *"Мы не делаем Evals, у нас вайб-коддинг"*. Это вызвало скандал. То есть, если вайбкодить, то делать оценку не надо?

Мнение Хамиля и Шреи:

1. Контекст решает всё

Разработчики используют AI для кода. Они сами — доменные эксперты. Инженер видит сгенерированный код и мгновенно понимает, какашка это или нет (dogfooding). Для юриста или врача такой "вайб" не прокатит — они не сидят часами, потребляя галлюцинации.

2. Семантическая ловушка

На самом деле, даже Claude Code основан на Evals. Фундаментальные модели обучены и оттестированы на бенчмарках. А когда инженер говорит "мне не нравится этот код" — он неявно проводит тот самый анализ ошибок.

Вывод: вайб-коддинг — это не отсутствие Evals, это сокращенный цикл обратной связи для очень специфичной аудитории (разработчики). Для всех остальных — нужны четкие метрики.

Часть 5. Практические советы: ROI и инструментарий

Главный совет: не стремитесь к совершенству. Цель — **Actionable Improvement** (улучшить продукт здесь и сейчас).

Как долго это занимает?

- **Первая итерация (Анализ ошибок):** 3-4 дня. Вы смотрите логи цепочек событий и кластеризируете.
- **Далее:** 30 минут в неделю. Вы прогоняете судей на новых данных (например, cron job раз в неделю по семплу из 1000 логов цепочек событий).

Совет: не ждите, что готовый инструмент сделает всё за вас. Хамиль показывает, что лучшие команды пишут свои тулзы под конкретный продукт (используя Cursor или Claude Code за пару часов). Зачем? Чтобы устранить всё, что замедляет или раздражает при просмотре логов. Например, скрыть системный промпт по умолчанию (не отвлекает), подсветить ошибки красным (сразу видно проблему), добавить кнопку "Добавить в eval" (один клик вместо пяти). Без таких важных улучшений люди часто устают и забрасывают анализ ошибок, но анализ ошибок — это самый высокоокупаемый процесс в AI-разработке.

Миф №2: У нас есть A/B тесты, зачем нам Evals?

Ответ на миф: A/B тест — это тоже форма Eval. Но A/B тест отвечает на вопрос "Какая версия лучше по метрике?". А анализ ошибок отвечает на вопрос "Почему и какие именно сценарии сломаны". Делать A/B тесты без предварительного анализа ошибок — стрелять из пушки по воробьям.

Итог: рождение новой PRD

Самое красивое, что показали в подкасте — **Evals как новая форма PRD** (Product Requirements Document).

Традиционный PRD: система должна вежливо отвечать и не галлюцинировать.

Eval (LLM-as-a-Judge): жесткий набор правил (True/False), который выводится из реальных данных. Вы не просто говорите "будь вежлив", вы учите судью отличать вежливый отказ от бесполезного спама.

Когда вы интегрируете этого судью в CI/CD, вы получаете **живой документ**, который защищает ваш продукт от регрессов так же, как юнит-тесты защищают бэкенд.

Вывод: Evals — это скучно? Нет. Это самая интересная и высокооплачиваемая роль в AI сегодня. Вы просто смотрите на диалоги вашего бота, ругаетесь на него, фиксируете и смотрите, как цифры падают (или растут). Попробуйте, и вы не сможете остановиться.

Теги: [искусственный интеллект](#), [управление продуктами](#), [управление продуктом](#), [управление проектами](#), [управление проектом](#), [искусственный интеллект](#)

Хабы: [Управление продуктом](#), [Управление проектами](#), [Искусственный интеллект](#)



Редакторский дайджест

Присылаем лучшие статьи раз в месяц

Подписаться

Оставляя почту, я принимаю [Политику конфиденциальности](#) и даю согласие на получение рассылок



64K+

2

Охват за 30 дней

Карма

Янина Шкуропат [@datamafia](#)

Практикую [Discovery](#)\[Delivery](#)\[Growth](#)\[Data Analytics](#)

Подписаться



[Telegram](#)

Поток Менеджмент доступен 24/7 благодаря поддержке друзей Хабра

Хабр Курсы для менеджеров

РЕКЛАМА

Практикум, Хекслет, SkyPro, авторские курсы — собрали всех и попросили скидки. Осталось выбрать!

Перейти


[Перейти в поток Менеджмент](#)

[Комментарии 3](#)

Публикации

ЛУЧШИЕ ЗА СУТКИ

ПОХОЖИЕ



the_bat

23 часа назад

Ремонт блока питания с Power Delivery. 470 граммов электроники

Простой

4 мин

16K

+96

30

27



interpres

18 часов назад

Электроинструмент становится хуже, и это делается намеренно

Простой

11 мин

26K

Обзор

Перевод

+70

45

82



prohronus

18 часов назад

Как ИИ-агенты стали новым оружием скамеров на Хабр Карьере

5 мин


9.3K

Кейс

+51

9

9



alizar

22 часа назад

Готовимся к отключению. Эффективные форматы для упаковки и раздачи HTML-страниц

Простой

7 мин


12K

Обзор

+37

59

18



beget_com

вчера в 12:05

Механический калькулятор. Как работает арифмометр?

Средний

10 мин

9.6K

Обзор

+37

23

8



TrexSelectel

19 часов назад

Linux 7.0 и что изменилось в ядре после очередного цикла разработки

5 мин

8.7K

Обзор

+27

10

0



AlexSerbul

23 часа назад

Программирование с AI-ассистентом — похороните меня под плинтусом

Средний

14 мин

9.9K

Мнение

+26

33

11



mariklolik

18 часов назад

Как переложить нагрузку по code review с разработчиков на LLM

Средний

7 мин

7.4K

Кейс

+23

23

6



nick_dyuba

22 часа назад

Легенды 90-х — кто придумал и производил жвачки Turbo, Love is... и TіріTір

5 мин

7.1K

Recovery Mode

+22

8

5



Mimizavr

23 часа назад

«Великое очищение» в работе с контентом: что осталось от роли редактора

11 мин

6.9K

+17

9


7

Тысяча нюансов: как управлять производством лекарств

Турбо


Показать еще

МИНУТОЧКУ ВНИМАНИЯ



Промо 

Запахло весной и скидками в
Промокодусе



Событие

Качаем к лету хард- и софт-скиллы
на айтишных ивентах



Турбо

Собери облачный пазл и выиграй
призы

КУРСЫ

 Специалист по искусственному интеллекту

По мере набора группы

 Менеджер проектов

По мере набора группы

 Нейросети. Практический курс

По мере набора группы

 ИТ-директор

По мере набора группы

 Философия искусственного интеллекта

По мере набора группы

[Больше курсов на Хабр Карьере](#)

ЧИТАЮТ СЕЙЧАС

Электроинструмент становится хуже, и это делается намеренно

 26K  82

Тим Кук покидает пост Apple. Новый глава — «отец» Apple Silicon Джон Тернус

 13K  14

Представлен проект KillerPDF — редактор PDF с открытым исходным кодом для Windows 10/11

 6.9K  15

Пользователь купил Atomic Heart на VK Play, но не смог запустить игру из-за сетевых проблем

 5.4K  11

+185% за 13 часов: как Kimi K2.6 переписала 8-летний движок

 14K  9

Тысяча нюансов: как управлять производством лекарств

Турбо

ИСТОРИИ




Годнота из блогов компаний



Только 10% решат эту головоломку




Хочу 450K



Вперёд к звёздам



Там на неведомых дорожках...



Самое время поспать

БЛИЖАЙШИЕ СОБЫТИЯ




2 марта – 10 августа

**PROBA Awards —
международная
коммуникационная
премия, учрежденная в
2000 году**

Санкт-Петербург

Маркетинг



3 марта – 9 июня


Экспедиция «Рэйдикс»

Екатеринбург • Новосибирск •
Краснодар • Минск • Калининград •
Ростов-на-Дону

Разработка

Другое

Больше событий в календаре




9 марта – 1 июня

**Всё, что нужно, чтобы
стартовать продвижение
бренда на Хабре**

Онлайн

Маркетинг

Больше событий в календаре



19 марта – 28 апреля

**Серия вебинаров
«Эволюция п
в облаке»**

Онлайн

Разработка

Больше событий в календаре

Ваш аккаунт

Войти
Регистрация

Разделы

Статьи
Новости
Хабы
Компании
Авторы
Песочница

Информация

Устройство сайта
Для авторов
Для компаний
Документы
Соглашение
Конфиденциальность

Услуги

Корпоративный блог
Медийная реклама
Нативные проекты
Образовательные программы
Стартапам



Настройка языка

Техническая поддержка