



Получите новый уровень в карьере

Повышайте свою квалификацию



Хабр



Чему научиться в этом году?



16K+

Охват за 30 дней

Инферит

88,78 Рейтинг

106 Подписчики

Подписаться



vazhendima


12 часов назад

ELT против ETL в FinOps: Почему мы сначала кладем сырые данные, а потом думаем

🗨 Средний 🕒 5 мин 👁 5.7K

Блог компании Инферит, Облачные вычисления*, Облачные сервисы*, DevOps*, Анализ и проектирование систем*

Обзор



«Фарш невозможно прокрутить назад» — этой поговоркой инженеры данных могли бы объяснить, как работает классический ETL. Ошибка может случиться на любом этапе: не тот коэффициент применили, не ту валюту подставили, забыли про скидку. Но после того как исходные данные трансформированы и отчет сформирован, но иногда бывают такие ситуации, когда вернуться к первоисточнику по какой-то причине уже нельзя.

В FinOps эта ситуация — не метафора, а суровая реальность. Данные от облачных провайдеров доступны лишь в ограниченном окне (30–90 дней), а иногда и меньше. Если вы сначала обработали их, а потом поняли, что ошиблись, может так случиться, что перезапросить исходники уже не получится.

В этой статье мы разберем два подхода к построению процессов обработки и преобразования данных — ETL и ELT — и докажем, почему для FinOps выбор ELT — это не просто вопрос производительности, а вопрос выживания исторических данных.

ETL vs ELT: два подхода к обработке данных

Классический ETL (Extract → Transform → Load):

1. Извлекаем данные из источника.
2. Трансформируем (чистим, обогащаем, агрегируем).
3. Загружаем результат в хранилище.

Плюсом этого подхода является то, что в хранилище лежит только «чистый» продукт, что экономит место. Однако есть и огромный минус — исходники просто не сохраняются в системе, и если информация была обработана некачественно переделать все заново будет иногда сложно — надо по новой извлекать данные из источника.

Альтернативный ELT (Extract → Load → Transform):

1. Извлекаем данные.
2. Сразу загружаем «как есть» в "сырое"/промежуточное хранилище.
3. Только потом, асинхронно, трансформируем.
4. Загружаем результат в постоянное хранилище.

Иными словами в ELT мы сначала сохраняем все, что пришло, в первозданном виде. А уже потом, в спокойном режиме, применяем любые трансформации. И если что-то пошло не так — всегда можно вернуться к изначальным вводным и обработать их заново.

Почему для FinOps ELT — это не «лучше», а «единственно возможно»?

Биллинговые API большинства провайдеров имеют глубину хранения — 30, 60, реже 90 дней, а метрики из мониторинга могут быть доступны и на более короткие сроки, и если окно загрузки пропущено данные теряются навсегда.

Пример из практики: Вы настроили ETL-процесс, он отработал, загрузил все необходимые данные. Через месяц вы поняли, что неправильно обрабатывали стоимость — не учли региональные коэффициенты. А исходный файл с детализацией за тот месяц уже не получить. Отчетность за этот период навсегда останется неверной.

Именно поэтому в архитектуру [Клаудмастер](#) мы изначально заложили принцип ELT.

Платформа сначала сохраняет «сырые» биллинги провайдеров в неизменном виде, и только потом применяет к ним движок трансформаций. Это дает нашим клиентам «право на ошибку»: если через полгода вам понадобится пересчитать исторические затраты, то Клаудмастер сделает это, обратившись к сохраненным первоисточникам

Поэтому при работе с внешними системами, которые не умеют хранить свою историю бесконечно, ELT — это единственная стратегия, которая сохраняет возможность пересчета и исправления ошибок.

Шаги трансформации: что мы делаем с данными после загрузки

Сохранить сырые данные — это только полдела. Главное — уметь превратить их в структурированную, непротиворечивую и удобную для анализа информацию. Для этого мы используем десять шагов работы с данными, каждый из которых решает свою задачу.

1. **Фильтрация.** Убираем все, что нам не нужно: служебные записи, тестовые аккаунты, данные, выходящие за пределы интересующего периода.
2. **Дедупликация.** Удаляем дубли. Например если один и тот же файл загрузился дважды по технической ошибке или биллинговая система сгенерировала две одинаковые записи.
3. **Очистка от мусора.** Что считать мусором — определяем сами. Это могут быть строки с нулевыми суммами, записи без идентификаторов, данные из неподдерживаемых регионов.
4. **Преобразование типов.** Например на входе пришла строка «03-02-2026», а мы ожидаем тип YYYY-MM-DD. На этом этапе приводим все к единому формату.
5. **Унификация.** Приводим данные к единому корпоративному стандарту. Например, телефоны: +7 (495) 123-45-67 → +74951234567 или email: User@Company.RU → user@company.ru.
6. **Исправление опечаток и неточностей.** Город «Москва» может прийти как «Москва», «Moscow», «г. Москва». Нужны правила, которые приведут все к единому значению.
7. **Обогащение.** Добавляем информацию, которой не было в исходных данных. Например, у нас есть идентификатор клиента, а мы добавляем его полное название из справочника НСИ. Или добавляем пометку «критичный клиент» на основе правил.
8. **Сопоставление (маппинг).** Связываем информацию из разных систем. Например, в биллинговом файле указан идентификатор виртуальной машины, а нам нужно добавить название проекта, к которому она относится. Для этого нужна таблица соответствий.
9. **Агрегация.** Собираем детальные данные в более крупные блоки. Например, поминутные показания нагрузки агрегируем до часовых или суточных. Это уменьшает объем данных и ускоряет формирование отчетов.
- 10.
11. **Нормализация/денормализация.** В зависимости от того, какую схему хранения мы выбрали, мы либо разносим данные по разным таблицам в 3NF, либо используем схему "Звезда", либо, наоборот, собираем все в одну широкую денормализованную таблицу.

Правила трансформации: как не превратить ELT в хаос

При большом количестве данных и их трансформаций возникает риск, что ELT системы просто невозможно будет поддерживать. Для решения этой проблемы согласовываются и документируются правила трансформации (Transform Rules и любое преобразование должно четко следовать этим правилам.

Что должно быть описано в Transform Rules:

- Источник и цель: откуда берем данные, в какую таблицу/слой кладем результат
- Схема отображения: какой атрибут источника в какой атрибут цели идет
- Логика преобразования: как из исходного значения получить целевое
- Типы данных: что ожидаем на входе, что получаем на выходе

Возможные форматы документирования:

- Таблицы отображения (Source-to-Target mapping): простое соответствие колонок
- Словари данных: описание каждой сущности в целевой системе с примерами

- ER-диаграммы: визуализация связей между сущностями
- Диаграммы потоков данных (Data Flow Diagrams): как данные движутся между слоями

Важно отметить: даже если вы не делаете идеальную документацию с первого дня, фиксируйте правила хотя бы в комментариях в коде или в Confluence. Потому что через три месяца никто, включая вас, не вспомнит, почему стоимость считалась именно так.

Почему для FinOps мы выбираем пакетную загрузку?

Данные обычно могут быть загружены двумя способами:

- потоковой загрузкой (streaming): записи приходят по одной, непрерывно
- пакетной загрузкой (batch): данные собираются в пакет и загружаются по расписанию (раз в час, раз в день...)

FinOps — это про управление расходами, а не про реакцию на каждое изменение инфраструктуры, здесь главное не скорость поступления, а надежность и возможность пересчитать. Поэтому и подход к загрузке данных должен быть соответствующим: размеренным, предсказуемым и удобным для перезапуска. Именно таким критериям отвечает **пакетная загрузка**.

12. Асинхронность: нет необходимости реагировать на каждое событие в реальном времени. Отчеты строятся раз в день, реже — раз в час.
13. Простота: пакетные процессы легче разрабатывать, тестировать и отлаживать.
14. Перезапускаемость: при ошибке легко перезапустить загрузку конкретного пакета, при потоковой загрузке процесс сильно усложняется.
15. Совместимость: API облачных провайдеров сами отдают данные порциями, а не потоком.

Конечно это не означает, что стриминг — зло. Для некоторых типов данных (например, алерты) он незаменим. Но для финансовых данных и метрик, которые ложатся в аналитическую систему, пакетная загрузка — это стандарт.

Заключение: ELT — это не про скорость, это про безопасность истории

В мире, где данные от внешних поставщиков имеют ограниченный срок хранения, классический ETL становится опасным. Вы рискуете потерять возможность исправить ошибки и пересчитать метрики. Выбор ELT — это стратегическое решение, которое обеспечивает:

Безопасность: исходные данные всегда доступны для пересчета.

Гибкость: можно менять логику трансформации, не перегружая внешние системы.

Аудит: всегда можно посмотреть, что пришло «как есть», и сравнить с результатом.

Теги: управление проектами, облачные вычисления, data warehouse, системная архитектура, it-инфраструктура, big data, devops, data engineering, finops, финопс

Хабы: Блог компании Инферит, Облачные вычисления, Облачные сервисы, DevOps, Анализ и проектирование систем

Редакторский дайджест

Присылаем лучшие статьи раз в месяц

Подписаться

Оставляя почту, я принимаю [Политику конфиденциальности](#) и даю согласие на получение рассылок



16K+

Охват за 30 дней

Инферит

[Сайт](#) [Telegram](#) [ВКонтакте](#)



16K+

Охват за 30 дней

14

Карма

Дмитрий Важенин [@vazhendima](#)

Пользователь

Подписаться



Поток Администрирование доступен 24/7 благодаря поддержке друзей Хабра

Хабр Курсы для админов

РЕКЛАМА

Практикум, Хекслет, SkyPro, авторские курсы — собрали всех и попросили скидки. Осталось выбрать!

Перейти

[Перейти в поток Администрирование](#)

Комментарии 2

Публикации

[ЛУЧШИЕ ЗА СУТКИ](#)

[ПОХОЖИЕ](#)



the_bat

23 часа назад

Ремонт блока питания с Power Delivery. 470 граммов электроники

Простой

4 мин

16K



+96



30



27



interpres

18 часов назад

Электроинструмент становится хуже, и это делается намеренно

 Простой  11 мин  26K

Обзор

Перевод

 +71

 45

 82



prohronus

19 часов назад

Как ИИ-агенты стали новым оружием скамеров на Хабр Карьере

 5 мин

 9.3K

Кейс

 +51

 9

 9



alizar

22 часа назад

Готовимся к отключению. Эффективные форматы для упаковки и раздачи HTML-страниц

 Простой

 7 мин

 12K

Обзор

 +37

 59

 18



TrexSelectel

19 часов назад

Linux 7.0 и что изменилось в ядре после очередного цикла разработки

 5 мин

 8.7K

Обзор

 +27

 10

 0



AlexSerbul

23 часа назад

Программирование с AI-ассистентом — похороните меня под плитусом

 Средний

 14 мин

 9.9K

Мнение

 +26

 33

 11



mariklolik

18 часов назад

Как переложить нагрузку по code review с разработчиков на LLM

 Средний

 7 мин

 7.4K

Кейс

 +23

 23

 6



nick_dyuba

22 часа назад

Легенды 90-х — кто придумал и производил жвачки Turbo, Love is... и TipiTip

🕒 5 мин 👁 7.1K

Recovery Mode

📦 +22

🔖 8

💬 5



Mimizavr

23 часа назад

«Великое очищение» в работе с контентом: что осталось от роли редактора

🕒 11 мин 👁 7K

📦 +17

🔖 9

💬 7



infgotoinf

10 часов назад

Perl — зря забытый язык программирования?

🕒 11 мин 👁 8.5K

Из песочницы

📦 +16

🔖 13

💬 8

Тысяча нюансов: как управлять производством лекарств

Турбо

Показать еще

МИНУТОЧКУ ВНИМАНИЯ

Турбо

Удалёнка в фарме: большие данные и никакой магии

Промо

Рассказываем в обновленном и расширенном курсе

Событие

Качаем к лету хард- и софт-скиллы на айтишных ивентах

ИНФОРМАЦИЯ

Сайт	inferit.ru
Дата регистрации	2 июня 2023
Численность	201–500 человек
Местоположение	Россия

БЛОГ НА ХАБРЕ

12 часов назад

ELT против ETL в FinOps: Почему мы сначала кладем сырые данные, а потом думаем

 5.7K  2

15 апр в 12:00

Дай нам силу, лунная... хотя нет, в нашем случае — «Призма данных»

 6.5K  1

13 апр в 12:17

Жучки — это не миф? Как прослушивают офисы и почему это сложно обнаружить

 8K  18

2 апр в 16:25


Кейс Клаудмастер: как редизайн интерфейса управления облачных бюджетов увеличил глубину сессии в 5 раз

 7.5K  0

26 мар в 11:31

Почему «зоопарк» ИТ-систем не исчезает даже когда все понимают, что это проблема

 7K  0




Годнота из блогов компаний



Только 10% решат эту головоломку



Хочу 450K






Вперёд к звёздам



Там на неведомых дорожках...



Самое время поспать



Ваш аккаунт

- Войти
- Регистрация

Разделы

- Статьи
- Новости
- Хабы
- Компании
- Авторы
- Песочница

Информация

- Устройство сайта
- Для авторов
- Для компаний
- Документы
- Соглашение
- Конфиденциальность

Услуги

- Корпоративный блог
- Медийная реклама
- Нативные проекты
- Образовательные программы
- Стартапам



Настройка языка

Техническая поддержка